

머신러닝응용 프로젝트 보고서

“Data-Centric 접근을 통한 YOLOv8 기반 흉부 CT 장기 분할 성능 개선”



AI학과 202378067 최희원

데이터 분석 및 데이터 전처리 설계
불균형 모델 코드 설계 및 분석 (Baseline 모델)
심장 정제 모델 코드 설계 및 분석 (실패 사례 분석)
해당 부분 보고서 작성 및 전체 수정

AI학과 202378042 이예진

심장 오버샘플링 모델 코드 설계 및 분석 (성공 사례 분석)
각 모델 결과 분석 및 시각화
성공 모델 영상 처리 및 분석
해당 부분 보고서 작성 및 전체 수정

제출일


2025년 12월 17일 수요일

1. 서론

의료 영상 분석에서 장기 분할(Segmentation)은 진단 보조 및 임상 의사결정의 정확도를 높이기 위한 핵심 기술이다. 특히 흉부 CT 영상은 폐, 심장, 기관과 같이 인접한 장기들이 포함되어 있어 경계가 불분명하고 형태적 편차가 커 정확한 분할이 어렵다. 또한 클래스 간 데이터 불균형으로 인해 심장과 같은 소수 클래스에서 과소 학습이 빈번히 발생하며, 모델이 다수 클래스(폐)에 편향되는 문제가 존재한다. 이러한 문제는 소수 장기에 대한 분할 정확도를 저하시켜, 실제 임상 환경에서 신뢰도 높은 진단 보조 시스템 구축에 제약으로 작용할 수 있다. 기존 연구는 주로 모델 구조 변경에 집중해 왔으나, 본 프로젝트는 모델 구조를 유지한 상태에서 데이터 구성과 분포 설계가 성능에 미치는 영향을 분석하는 데 목적이 있다.

2. 방법론

본 프로젝트에서는 YOLOv8s-seg 모델을 사용한다. YOLOv8s-seg는 객체 검출과 분할을 동시에 수행하는 polygon 기반 end-to-end segmentation 모델로, 단일 네트워크 구조를 통해 빠른 추론과 실시간 적용이 가능하다. 다만 데이터 품질과 클래스 분포에 민감하다는 한계가 있어, 본 연구에서는 모델 구조를 변경하지 않고 데이터 구성과 학습 전략 변화가 성능에 미치는 영향을 분석한다.



선택한 데이터셋은 Kaggle에 공개된 Chest CT Segmentation 데이터셋으로, 폐·심장·기관의 다중 클래스 분할이 가능한 의료 영상 데이터이다. 원본 데이터는 NRRD 형식으로 제공되며 각 CT 슬라이스에는 세 장기에 대한 분할 마스크가 포함되어 있다. 본 프로젝트에서는 해당 데이터를 YOLOv8-seg 모델 학습에 적합하도록 RGB 이미지와 polygon 기반 라벨 형식으로 변환하여 사용하였다. 또한 데이터셋의 특성을 분석하기 위해 클래스 분포를 계산한 결과, 전체 16,708장 중 폐 클래스 12,827장, 심장 클래스 3,626장, 기관 클래스 7,808장으로 나타나 뚜렷한 클래스 불균형이 존재함을 확인했다. 이러한 데이터 특성은 모델이 다수 클래스에 편향될 가능성을 높이고, 소수 클래스의 특징 학습과 경계 예측에 불리하게 작용할 수 있다. 이에 본 프로젝트는 샘플 수가 가장 적은 심장 클래스를 중심으로, 데이터 중심(Data-centric) 관점에서 데이터 구성 방식의 단계적 변화를 적용하여 분석하고자 세 가지 데이터 전략을 설계했다.

1. Imbalanced (Baseline) : 첫 번째 데이터 전략은 Imbalanced(Baseline) 구성으로, 원본 흉부 CT 데이터셋의 클래스 분포를 유지한 상태에서 학습 데이터를 구성한다. 폐, 심장, 기관 클래스의 학습 데이터 수를 각각 600, 100, 300으로 설정하여 클래스 불균형을 그대로 반영하며,

학습·검증·테스트 데이터는 8:1:1 비율로 분할한다. 이 과정에서 마스크의 형태나 경계에 대한 추가적인 필터링은 수행하지 않으며, 본 전략은 이후 데이터 중심 전략의 효과를 비교하기 위한 기준선으로 활용된다.

2. Balanced + Heart Refined : 두 번째 데이터 전략은 클래스 불균형 완화와 심장 클래스 데이터 품질 개선을 동시에 고려한 Balanced + Heart Refined 구성이다. 전체 학습 데이터 풀을 기준으로 폐, 심장, 기관 클래스의 데이터 수를 각각 400, 300, 300으로 조정하여 균형에 가까운 분포로 재구성한다. 또한 심장 클래스에 한해 polygon 점 개수와 최소 bounding box 면적 기준을 적용하여 형태 정보가 부족한 샘플을 제외하는 라벨 품질 정제를 수행하며, 폐와 기관 클래스에는 별도의 필터링을 적용하지 않는다.

3. Balanced + Heart Oversampling + Data Augmentation : 세 번째 데이터 전략은 소수 클래스의 학습 노출 빈도와 데이터 다양성을 동시에 조절하는 데 초점을 둔다. 동일한 클래스 분포를 유지한 상태에서 심장 클래스가 포함된 이미지의 학습 노출 빈도를 증가시키기 위해 텍스트 기반 학습 방식을 활용한 오버샘플링 전략을 적용한다. 또한 오버샘플링으로 인한 데이터 다양성 한계를 보완하기 위하여 의료 영상 특성을 고려한 제한적 데이터 증강을 함께 적용한다. Copy-Paste, 소규모 이동 및 크기 변화와 같은 보수적인 증강만을 사용하여 장기 경계의 구조적 왜곡을 최소화하도록 설계한다.

- 시스템 구조 또는 파이프라인

1. 데이터 전처리 및 데이터셋 구성 : Imbalanced 구성은 원본 데이터 분포를 유지하여 클래스별 학습 데이터를 600/100/300으로 구성한다. Balanced + Heart Refined 구성에서는 데이터 분포를 400/300/300으로 조절하고, 심장 클래스에 대해 polygon 형태 정보가 부족한 샘플을 제거하는 라벨 품질 정제를 적용한다. Heart Oversampling 구성에서는 동일한 분포를 유지한 채 심장 클래스 이미지의 학습 노출 빈도를 증가시키는 데이터 구성 전략을 사용한다.

2. YAML 설정 파일 생성 및 데이터 로딩 : Imbalanced 및 Balanced + Heart Refined 구성에서는 폴더 기반(images/train, images/val) 데이터 로딩 방식을 사용한다. 반면 Heart Oversampling 구성에서는 심장 클래스의 반복 학습을 위해 학습 이미지 경로를 .txt 파일로 관리한다. 검증 단계에서는 모든 실험에서 동일한 test 데이터셋을 사용하여 모델 간 성능 비교의 공정성을 확보한다.

3. 모델 학습 : 모든 실험은 동일한 사전 학습 모델인 yolov8s-seg.pt를 기반으로 파인 튜닝 방식으로 수행되며, epochs, batch size, 입력 이미지 크기 등 학습 하이퍼파라미터는 모든 모델에서 동일하게 설정한다. Heart Oversampling 구성에서는 의료 영상의 형태 왜곡을 방지하기 위해 mosaic과 mixup은 비활성화하고, 제한적인 copy-paste, scale, translate 증강만을 적용한다.

4. 검증 및 성능 평가 : 학습 과정에서는 validation 데이터셋을 통해 모델의 수렴 상태를 확인하고, 최종 성능 평가는 모든 모델에 대해 동일한 test 데이터셋을 사용하여 수행한다. 평가는 IoU, mAP 등의 정량 지표와 예측 결과 시각화를 기반으로 한 정성적 분석을 통해 시행하며, 데이터 구성 전략에 따른 성능 차이를 종합적으로 비교하는 데 목적을 둔다.

- 학습 설정 및 환경

본 연구의 모든 실험은 동일한 학습 설정과 실행 환경에서 수행한다. YOLOv8s Segmentation

모델(yolov8s-seg.pt)을 기반으로 사전 학습 가중치를 활용한 파인튜닝을 적용하며, epoch 50, batch size 16, 입력 해상도 640, early stopping 기준 30으로 학습을 진행한다. 클래스 순서는 lungs, heart, trachea로 모든 실험에서 동일하게 유지하고, 학습은 train과 validation 데이터만을 사용하여 8:2 비율로 분할한다. test 데이터셋은 기존 분할을 고정하여 모든 모델에서 동일하게 사용함으로써 공정한 성능 비교가 가능하도록 구성한다. 모든 실험은 Google Colab 환경에서 GPU 자동 할당(device="auto")을 통해 수행되며, 이를 통해 모델 구조나 학습 조건의 차이가 아닌 데이터 구성 전략의 차이만이 성능 변화에 영향을 미치도록 통제한다.

3. 실험 결과


- 정량적 평가

전체 분할 성능 기준으로 Finetune(Imbalanced) 모델은 Mask mAP50 0.807, mAP50-95 0.622로 안정적인 성능을 보였다. 반면 Finetune(Heart Refined) 모델은 Mask mAP50 0.703, mAP50-95 0.515로 크게 하락하여, 특정 클래스 중심 정제가 전체 성능 저하로 연결될 수 있음을 확인했다. Balanced(HeartBoost) 모델은 Mask mAP50 0.804, mAP50-95 0.602로 Finetune(Imbalanced)와 유사한 전체 성능을 유지하면서, 소수 클래스 성능 개선 가능성을 보여줬다.

클래스별로 보면, 폐(lung)는 세 모델 모두 높은 성능을 보였으나 Finetune(Imbalanced) 모델이 Mask mAP50-95 0.818로 가장 높았고, Finetune(Heart Refined) 모델은 0.745로 감소했다. Balanced(HeartBoost) 모델은 0.796으로 다수 클래스 성능을 크게 훼손하지 않는 수준을 유지했다. 심장(heart)에서는 모델 간 차이가 가장 크게 나타났는데, Finetune(Imbalanced) 모델은 정밀도 0.642, 재현율 0.683, Mask mAP50 0.646을 기록한 반면 Finetune(Heart Refined) 모델은 재현율 0.390, Mask mAP50 0.422로 크게 저하됐다. Balanced(HeartBoost) 모델은 정밀도 0.802, 재현율 0.591, Mask mAP50 0.665로 가장 우수한 심장 분할 성능을 보였다. 기관(trachea)에서도 Balanced(HeartBoost) 모델은 Mask mAP50-95 0.594로 Finetune(Imbalanced)와 유사한 수준을 유지했다.

IoU 비교에서도 동일한 경향이 확인됐다. Finetune(Imbalanced) 모델은 Mean IoU 0.6760을 기록했으며, Finetune(Heart Refined) 모델은 Heart IoU 0.2988로 크게 하락해 Mean IoU 0.5770으로 가장 낮았다. 반면 Balanced(HeartBoost) 모델은 Heart IoU 0.5585로 가장 높았고 (Imbalanced 대비 +0.041, Heart Refined 대비 +0.260) Mean IoU 역시 0.6804로 세 모델 중 가장 우수했다.

- 정성적 분석



정성 평가는 학습에 사용되지 않은 Test set 이미지 1장을 무작위로 선택하여 수행했다. 모든 모델은 동일한 시각화 규칙을 적용했으며, 폐는 파란색, 심장은 초록색, 기관은 빨간색으로 고정했다. 예측 마스크는 임계값 0.5 기준으로 이진화한 뒤 클래스별 마스크를 통합해 원본 영상에 오버레이했다.

Finetune(Imbalanced) 모델은 폐 영역은 비교적 잘 분할되었으나 심장은 거의 분할되지 않거나 배경과 혼동되는 양상이 관찰됐다. Finetune(Heart Refined) 모델은 심장 분할이 충분히 확보되지 않았고 폐 영역에서도 일부 불완전한 분할이 나타났다. 반면 Balanced(HeartBoost) 모델은 폐와 심장이 명확히 구분되어 분할됐고, 심장 영역도 해부학적 위치에 맞게 안정적으로 예측되었다.

추가적으로 Balanced(HeartBoost) 모델은 실시간 영상 입력에서도 폐·심장·기관을 안정적으로 구분하며, 연속적인 프레임 환경에서도 예측 안정성과 실사용 가능성을 확인했다.

- 결과 해석

Finetune(Imbalanced) 모델은 전체 성능은 안정적이지만 심장 분할에서 한계를 보였고, Finetune(Heart Refined) 모델은 정제 과정이 오히려 분포 붕괴로 이어져 전반적인 성능이 저하된 실패 사례로 분석된다. Balanced(HeartBoost) 모델은 이미지 수를 증가시키지 않은 상태에서 심장 노출 빈도 조절과 제한적 증강을 결합해 심장 성능을 개선하면서도 폐와 기관 성능을 유사 수준으로 유지하였다. 정량적, 정성적 결과 모두에서 이러한 경향이 일관되게 확인되었으며, 모델 구조나 파라미터 변경 없이 Data-Centric 접근만으로 소수 클래스 성능과 전체 분할 균형을 동시에 개선할 수 있음을 보여준다.

4. 결론

본 프로젝트는 흉부 CT 장기 분할에서 발생하는 클래스 불균형과 소수 클래스(심장)의 학습 불안정성 문제를 정의하고, 이를 모델 구조 변경이 아닌 데이터 구성 방식의 변화만으로 완화할 수 있는지를 분석하는 데 목적을 두었다. 동일한 YOLOv8s-seg 모델과 학습 설정을 유지한 상태에서, Imbalanced, Balanced + Heart Refined, HeartBoost의 세 가지 Data-centric 전략을 단계적으로 비교함으로써 데이터 수 조정, 라벨 품질 개선, 학습 노출 빈도 및 데이터 다양성 변화가 분할 성능에 미치는 영향을 분석했다. 그 결과 소수 클래스 분할 성능 향상에는 단순한 데이터 수 균형보다 학습 노출 빈도와 데이터 다양성을 함께 고려한 Data-centric 전략이 중요함을 확인했다. 또한 정성적 분석과 영상 분할 실험을 통해 HeartBoost 모델이 미학습 영상과 동적 환경에서도 안정적인 일반화 특성을 보임을 발견했다.

본 연구의 한계로는 심장 클래스의 재현율이 개선되었음에도 불구하고 여전히 완전한 수준에는 도달하지 못했다는 점과, 오버샘플링 비율 및 데이터 증강 강도에 따라 성능이 민감하게 변할 수 있다는 점이 있다. 이는 데이터 중심 접근만으로는 경계가 모호한 장기 분할 문제를 완전히 해결하는 데 한계가 있음을 시사한다. 이에 따라 향후 연구에서는 경계 인식 손실 함수나 attention 기반 기법을 결합하여, 데이터 전략을 보완하는 모델 수준의 접근을 함께 고려할 필요가 있다. 또한 본 연구에서 제안한 데이터 구성 전략을 다양한 의료 영상 데이터셋에 확장 적용함으로써, 소수 클래스 분할에 대한 일반화 가능성을 추가로 검증할 필요가 있다.

Chatgpt : 본 프로젝트 수행 과정에서 AI 도구는 실험 설계 구조 정리, 코드 이해 보조를 하는데 활용되었다.